Brecha digital y no uso de internet en estudiantes de 6-17 años: integración ENAHO-ESCALE 2025

Inteligencia Artificial | Ingeniería de Sistemas | Universidad Peruana Unión
Docente: Mg. Angel Rosendo Condori Coaquira

Resumen

Se integraron ENAHO y ESCALE 2025 para analizar 16 544 residentes de 6-17 años matriculados y asistentes a primaria/secundaria. El objetivo fue clasificar el **no uso de internet en el mes anterior**, indicador operativo que no mide competencias digitales. Se compararon dos métodos de agrupamiento y cuatro clasificadores mediante cinco folds por conglomerado. CatBoost obtuvo la mayor AP de validación; en prueba alcanzó ROC-AUC=0.820, AP=0.601 y F1 macro=0.693. Los perfiles presentan no uso ponderado entre 21.1% y 47.7% en desarrollo. Se auditaron estabilidad del clustering, estrategias de peso y explicaciones SHAP del ganador y de un árbol no lineal. El diseño es transversal; los resultados describen asociaciones predictivas y requieren validación externa.

Palabras clave: ENAHO; ESCALE; brecha digital; validación agrupada; clustering; SHAP.

1. Problema, medición y alcance

La conexión del hogar no garantiza el uso efectivo de internet. Se busca identificar perfiles socioeconómicos y tecnológicos, comparar modelos de no uso y explicar sus decisiones con contexto educativo de distrito y área [1-3]. La cohorte contiene 4 294 no usuarios y 12 250 usuarios: 26.0% muestral y 22.7% ponderado, sin presentarlo como tasa oficial nacional. Clase 1: P314A=2; clase 0: P314A=1; ausencias y pases no se convierten en ceros.

Antes de modelar se contrastó el desfase edad-grado: los umbrales de uno y dos años produjeron 6 707 y 679 positivos, respectivamente. No se reconstruyó edad al 31 de marzo en esta integración; el desfase observado varía con el mes y no equivale al indicador ESCALE [4]. Se eligió no uso por su medición directa, sin comparar AUC para decidir la etiqueta.

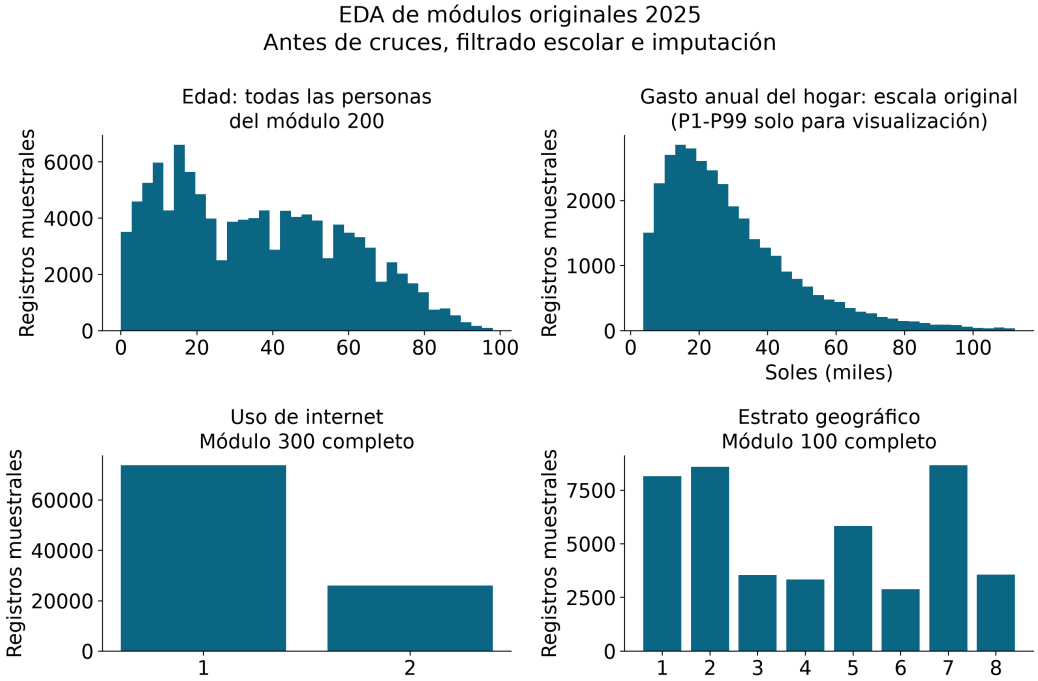


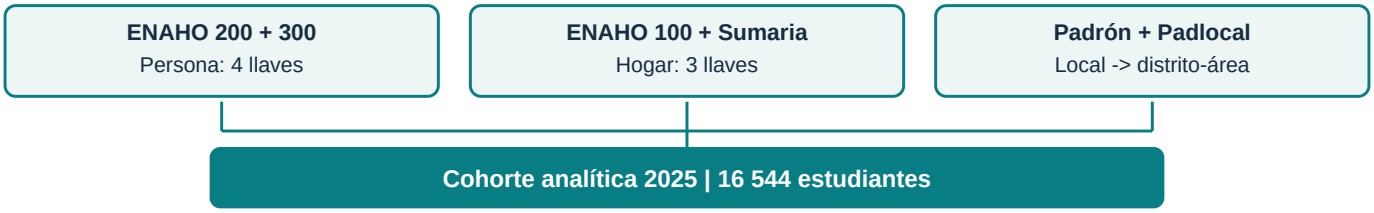
Figura 1. EDA de módulos originales antes de cruzar y filtrar la cohorte. El recorte P1-P99 del gasto es sólo visual: no elimina observaciones analíticas. Se conservan valores originales, faltantes y dominios en las tablas de auditoría.

En desarrollo (n=13 105), el no uso ponderado fue 39.6% en área rural y 18.4% en urbana. La figura EDA de la cohorte y los estadísticos previos a imputar acompañan la entrega; son comparaciones descriptivas.

Competencias: alcance parcial. P316B/P316C sólo aplica desde 14 años: 5 041 elegibles, 2 097 autorreportes completos de nueve actividades y 77 sin actividades reportadas. Los saltos del cuestionario se trataron como ausencia estructural de observación. Este universo restringido y el carácter autorreportado de las actividades impiden definir un indicador de competencias comparable para toda la cohorte.

2. Datos, integración y evaluación reproducible

Se integraron los módulos anuales de vivienda, población y educación de ENAHO 2025 (100, 200 y 300), la base Sumaria y los padrones de servicios educativos y locales escolares de ESCALE [1,2]. Los registros se enlazaron mediante identificadores de persona, hogar y territorio. El contraste con el corte 2025 del panel ENAHO confirmó la concordancia de los valores comunes utilizados, una vez homogeneizados los formatos.



Paso de construcción	Registros / comprobación
Personas ENAHO 2025	115 145
Edad 6-17 antes / después de residencia	24 195 / 23 345
Cruces educación, vivienda y Sumaria	educacion: 100.0%; vivienda: 100.0%; sumaria: 100.0%
Contexto ESCALE en base integrada	22 920 / 23 345 (98.2%)
Servicios Padrón enlazados a Padlocal	54 038 / 54 038; conflictos geográficos: 1
Cohorte matriculada y asistente EBR	16 544; sin declaración CEBA
Desarrollo / prueba	13 105 / 3 439 personas; 3 232 / 808 conglomerados

Calidad y exploración de datos. Se verificaron Latin-1, separador punto y coma y coma decimal en los anuales; el panel usa UTF-8 con BOM y coma de separación. Se inspeccionaron faltantes, tipos, dominios, llaves, cuantiles y extremos; los geocódigos conservan ceros iniciales. Se verificaron la unicidad de los identificadores y la cardinalidad de los cruces, sin multiplicación de personas. La exploración de predictores se realizó exclusivamente en desarrollo; las tablas complementarias describen los faltantes y las distribuciones originales.

Cruce contextual. ENAHO 200 y 300 se enlazaron por CONGLOME, VIVIENDA, HOGAR y CODPERSO; 100 y Sumaria, por las tres llaves del hogar. Padrón se unió a Padlocal por CODLOCAL y se filtraron servicios activos de primaria/secundaria. La agregación por UBIGEO y área usa suma de alumnos / suma de docentes, proporción pública y coordenadas del Padrón contadas una vez por local validado (43 631 locales). Padlocal permitió validar la correspondencia geográfica; las coordenadas proceden del Padrón. Se excluyó de la validación geográfica el registro con conflicto territorial.

Prevención de fuga de información. Se exige residencia habitual, edad 6-17, P306=P307=1, P308A primaria/secundaria, no declaración CEBA y P314A válido. Se excluyeron la respuesta, las ramas condicionadas P314B/P314D/P315/P316, sus derivados, llaves, coordenadas, mes y campos de escolaridad propios. GroupShuffleSplit (semilla 42) separó conglomerados: solapamiento=0. Cinco folds GroupKFold en desarrollo sustentan ajuste y selección; sus predicciones fuera de fold alimentan la calibración. Mediana/moda, one-hot y escalado se ajustaron sólo en cada entrenamiento.

Predictores y pesos. Se conservaron 13 variables individuales, socioeconómicas, de acceso y contexto. Ingreso y gasto per cápita mensual se transformaron con log(1+x). FACPOB07_25 es el peso anual de población. Por familia se compararon entrenamiento uniforme, peso poblacional, balance de clase y ambos, con métricas poblacionales comunes. Se eligió por AP-CV en una configuración representativa y luego se ajustaron hiperparámetros; es una búsqueda secuencial, no exhaustiva ni anidada.

Alcance de la evaluación. El conjunto de prueba había sido examinado previamente; por ello, la evaluación es retrospectiva y requiere confirmación externa independiente. La selección de modelos e hiperparámetros se realizó mediante validación cruzada en desarrollo.

3. Clustering: comparación, estabilidad y perfiles

Se compararon K-Means y mezclas gaussianas (GMM), k=2,...,6, con imputación y estandarización ajustadas en desarrollo. Se usaron log ingreso/gasto, altitud, alumnos/docente, proporción pública y acceso a electricidad e internet del hogar. La etiqueta sólo caracteriza los perfiles después del ajuste; los clusters no se incorporaron al clasificador. La regla previa priorizó silueta entre soluciones con grupos de al menos 5%, con Davies-Bouldin como desempate.

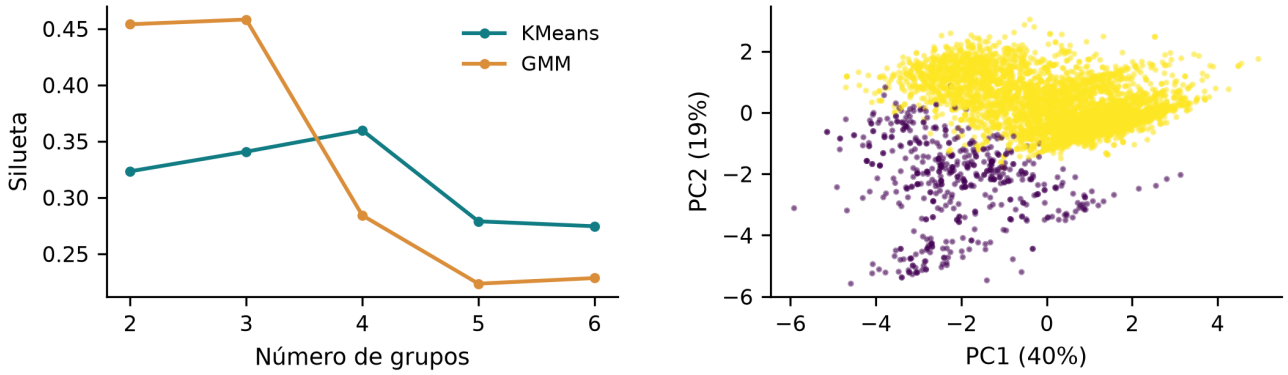


Figura 2. Silueta por método y PCA del seleccionado. La comparación estima silueta en 2 500 casos reproducibles. PCA es visualización y explica 59.0% de varianza.

Mejor elegible	k	Silueta	Davies-B.	Calinski-H.	Mínimo
GMM	2	0.454	1.452	3037.7	9.7%
KMeans	2	0.323	1.398	5337.3	37.9%

Se seleccionó **GMM, k=2**: silueta 0.454, Davies-Bouldin 1.452 y Calinski-Harabasz 3037.7. Los tres criterios pueden discrepar; no se interpreta una única partición como verdad poblacional. En la tabla, n es muestral y las medias/proporciones son ponderadas dentro de desarrollo.

Perfil	n	Rural	Internet hogar	Gasto S/ mes*	No uso
G0: Menor conectividad; rural	1 271	58.9%	48.6%	474	47.7%
G1: Mayor conectividad; urbano	11 834	18.3%	100.0%	705	21.1%

* Gasto per cápita. Internet del hogar incluye fijo/móvil; electricidad y conexión son dimensiones de acceso, no competencias digitales.

Estabilidad. Se repitió el método/k seleccionado cambiando semilla y ajustando en submuestras de 80% de desarrollo (6 réplicas). El índice Rand ajustado (ARI) frente a la partición original varió entre 1.000 y 1.000. Al quitar electricidad e internet del hogar, la silueta fue 0.279 y el ARI frente al agrupamiento completo 0.081. Esta ablación comprueba dependencia del acceso; no selecciona un nuevo modelo con la etiqueta. Las binarias pueden dominar la geometría, por lo que los nombres de perfiles son descripciones y no tipos sociales esenciales.

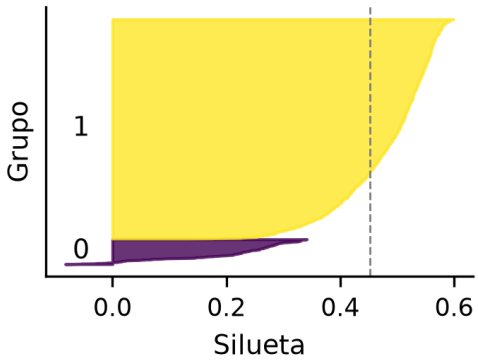


Figura 3. Distribución de silueta del método elegido en hasta 1 800 casos. Las diez soluciones y las réplicas se incluyen en las tablas reproducibles.

4. Clasificación: selección, sensibilidad y errores

Se compararon 16 combinaciones familia-peso y 24 configuraciones HP en cinco folds: 200 ajustes. Se variaron regularización logística, profundidad, hojas y submuestreo en Random Forest, profundidad/regularización en XGBoost y CatBoost. La selección usa AP-CV; parámetros completos en el código. AP y PR-AUC trapezoidal son resúmenes distintos de la curva PR.

Familia	Peso elegido	Rango AP-CV por peso	Candidatos HP
CatBoost	balance de clase	0.582-0.593	6
Logística	uniforme	0.585-0.587	6
Random Forest	uniforme	0.572-0.581	6
XGBoost	uniforme	0.582-0.591	6

Modelo	AP-CV ± DE	AUC prueba	PR-AUC prueba	F1 macro
CatBoost *	0.5935 ± 0.0109	0.820	0.601	0.693
XGBoost	0.5931 ± 0.0163	0.817	0.595	0.688
Logística	0.5886 ± 0.0256	0.816	0.585	0.680
Random Forest	0.5809 ± 0.0248	0.814	0.584	0.674

* Ganador CV nominal: CatBoost; diferencias pequeñas no demuestran superioridad estadística. CV usa scores sin calibrar; prueba usa sigmoide sobre predicciones fuera de fold de desarrollo y umbral 0.5. El orden de prueba no cambia la selección.

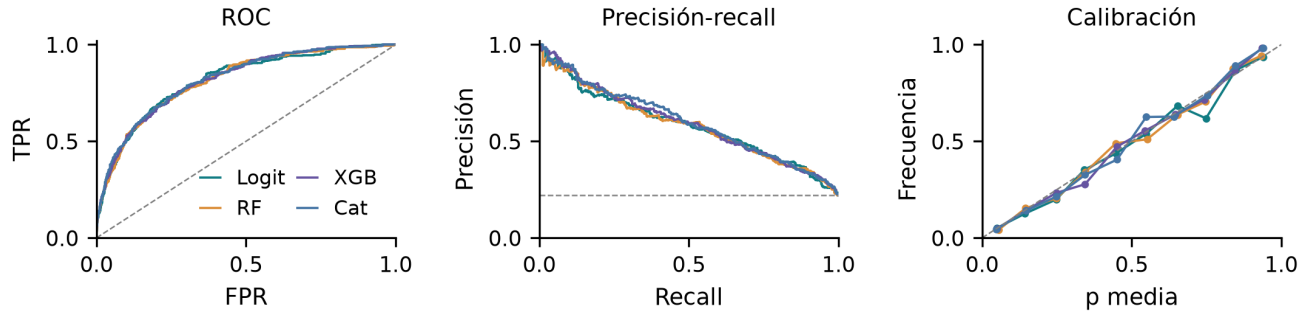
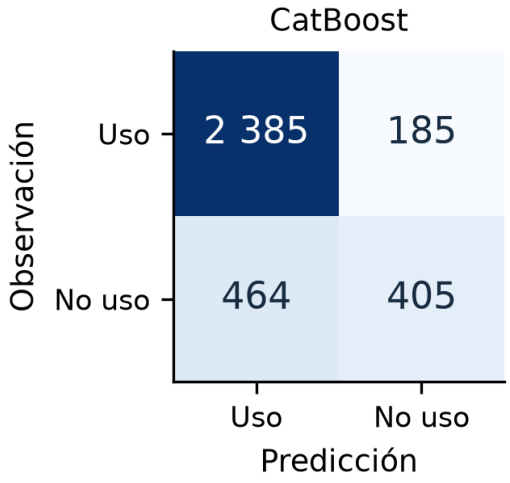


Figura 4. ROC, PR y calibración ponderadas. Referencia PR: prevalencia; diagonal de calibración: acuerdo ideal. Logit: logística; RF: Random Forest; XGB: XGBoost; Cat: CatBoost.

El ganador alcanzó AP 0.601 (IC 95% 0.552-0.645) y ROC-AUC 0.820 (IC 0.792-0.846); 300 bootstraps de conglomerados no reproducen todo el diseño estratificado. Brier: 0.162 sin calibrar y 0.127 calibrado; AP sin ponderar=0.665. La constante de prevalencia logra AP=0.220 y Brier=0.172; se prefiere AP para esa referencia porque el trapecio PR es sensible a empates e interpolación.



Errores al umbral 0.5.
405 verdaderos positivos, 464 falsos negativos y 185 falsos positivos (conteos). Precisión ponderada=69.1%; recall=38.1%. Omitir no usuarios puede dejar necesidades sin detectar; un falso positivo requiere verificación adicional. El modelo no debe excluir apoyos automáticamente. Las tasas ponderadas no se calculan a partir de esta matriz sin ponderar. No se optimizó el umbral con prueba.

Figura 5. Matriz de confusión de CatBoost en el conjunto de prueba. Evaluación retrospectiva; conteos sin ponderar.

5. SHAP del ganador e interacciones no lineales

Se explicó CatBoost en 601 casos de prueba, mediante TreeSHAP nativo de CatBoost con su referencia de árboles. Las dummies se sumaron por variable original. Las contribuciones están en **log-odds** antes de calibrar; no son puntos porcentuales de la probabilidad final. Residuo aditivo máximo=6.22e-15. La importancia global es media absoluta no ponderada de SHAP de esta muestra, no efecto poblacional ni causal.

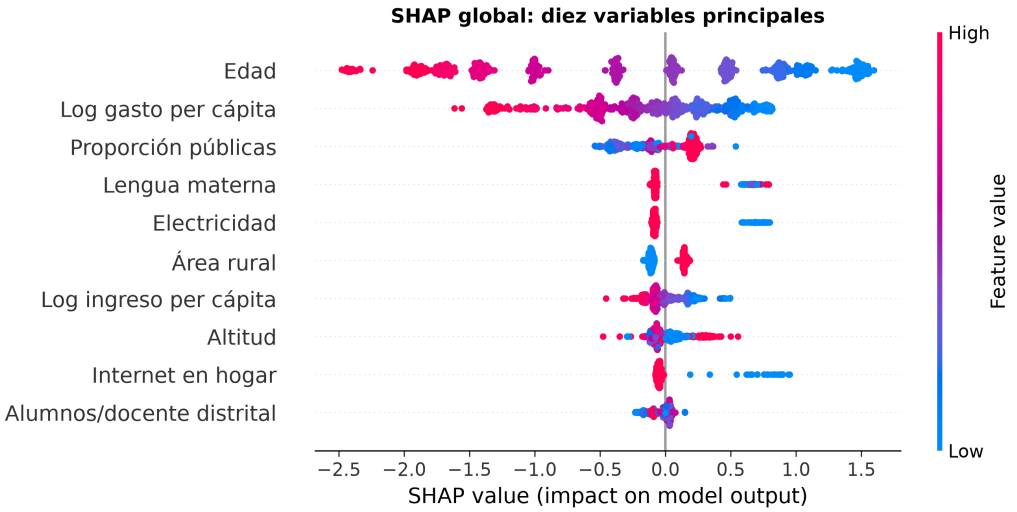


Figura 6. Diez variables principales del ganador. Destacan edad, log gasto per cápita, proporción pública. Positivo aumenta el score de no uso; categorías se muestran con sus códigos, no como escala ordinal.

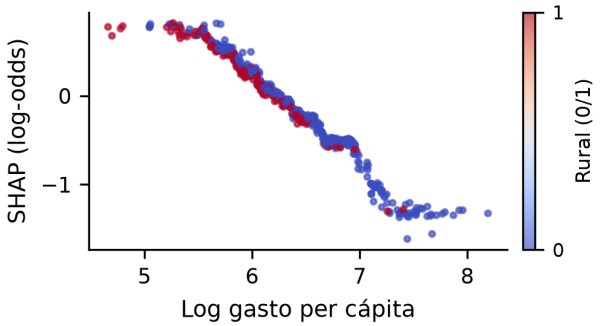


Figura 7. Dependencia del ganador: gasto per cápita, coloreado por ruralidad.

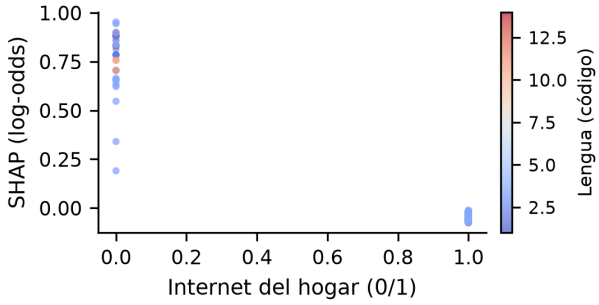


Figura 8. Dependencia del ganador: internet del hogar, coloreado por lengua.

Análisis no lineal de XGBoost. Análisis complementario; no sustituye al ganador. En 180 casos, TreeSHAP path-dependent usa cobertura de hojas de desarrollo. La media absoluta de la contribución del par (2ϕij) fue altitud × proporción pública: 0.039; altitud × alumnos/docente distrital: 0.028. Los pares se eligieron exploratoriamente entre variables de contexto/acceso; no son pruebas de significación.

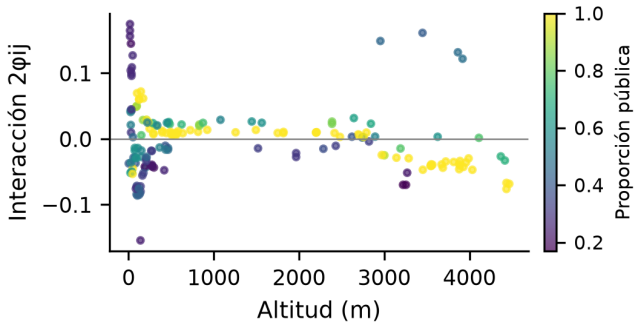


Figura 9. Interacción TreeSHAP del primer par: contribución 2ϕij al score.

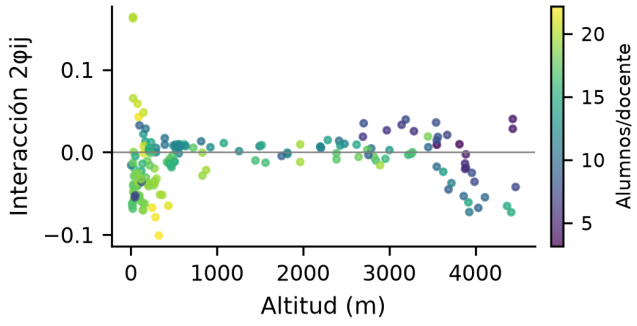
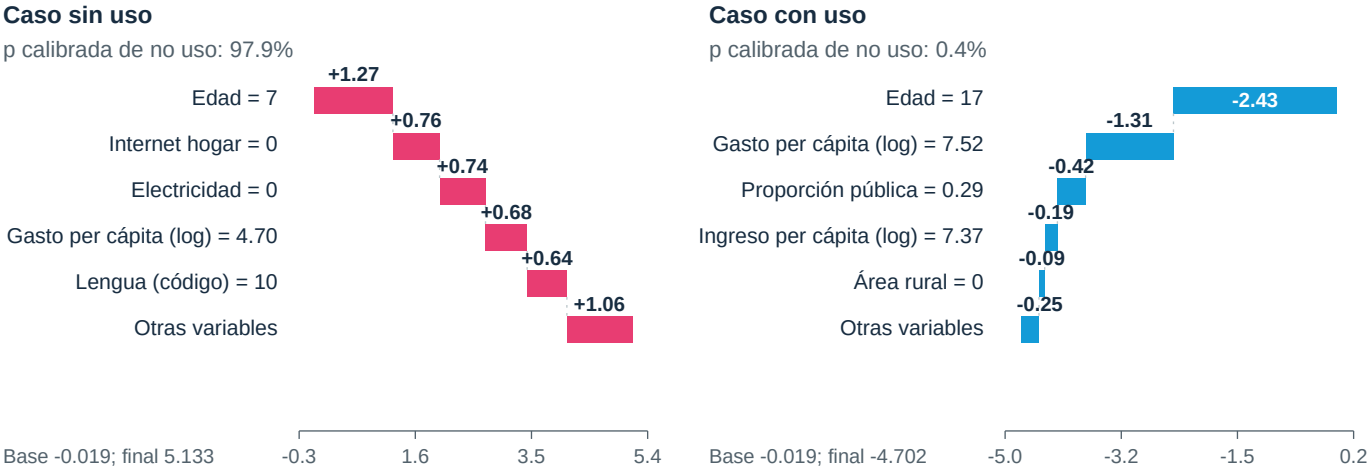


Figura 10. Interacción TreeSHAP del segundo par. Colores: otra variable del par.

Las interacciones no lineales pertenecen al árbol ajustado, no a personas ni políticas. La suma de interacciones y efectos principales reproduce el score (residuo 2.38e-06). La lengua y otros atributos requieren especial cautela por tamaños minoritarios, correlación y contexto. No se interpretan sus contribuciones como causas ni como criterio para negar servicios.

6. Casos individuales, conclusiones y límites



Figuras 11 y 12. Waterfalls SHAP del score antes de calibrar (log-odds), con cinco contribuciones principales y el resto agregado. Base + contribuciones = score final; la probabilidad calibrada se informa por separado.

Alto score: edad (+1.27), internet del hogar (+0.76). Bajo score: edad (-2.43), log gasto per cápita (-1.31). Los extremos correctamente clasificados ilustran el comportamiento del modelo y se presentan sin identificadores personales. Su selección es ilustrativa y no representa la distribución de toda la cohorte.

Conclusiones. La integración conserva cardinalidad y separación de conglomerados. Los perfiles presentan no uso entre 21.1% y 47.7% en desarrollo; las réplicas y la ablación permiten valorar su estabilidad. CatBoost fue seleccionado por AP-CV tras comparar pesos e hiperparámetros; su recall ponderado de 38.1% al umbral 0.5 limita la detección individual. La evidencia sugiere explorar apoyos de acceso y acompañamiento apropiados a edad y contexto y evaluar su efecto en campo. SHAP explica el score, no estima el impacto de intervenciones.

Limitaciones. No uso en el mes anterior no equivale a falta de habilidades, mala conexión ni exclusión permanente. Se excluyen no asistentes. ESCALE representa residencia, no escuela identificada, e incluye imputaciones; un distrito puede aparecer en ambas particiones. Las estrategias de peso y HP se eligieron secuencialmente en los mismos folds, por lo que CV puede ser optimista. La evaluación es retrospectiva sobre una partición de prueba previamente examinada y requiere validación externa independiente. Los pesos y bootstraps no reproducen todo el diseño muestral. La medición transversal, las referencias temporales y los predictores correlacionados impiden causalidad; se requiere nueva validación espacial/temporal antes de uso decisorio.

Referencias y materiales reproducibles

[1] INEI. Encuesta Nacional de Hogares, 2025: módulos 100, 200, 300 y Sumaria. MINEDU. ESCALE: Padrón de Servicios Educativos y Padrón de Locales Escolares, 2025.

[2] INEI. ENAHO 2025: Diccionario de Datos. Lima, mayo de 2026. Documento anual oficial. Cuestionarios ENAHO.01 y ENAHO.01A 2025 incluidos en los archivos suministrados.

[3] Condori Coaquira, A. R. Guía de Evaluación: Proyecto IA, Brecha Digital y Educación 2025 (ENAHO-ESCALE). Universidad Peruana Unión. Material del curso Inteligencia Artificial, 7 p.

[4] INEI. Documento Metodológico de los Indicadores en Educación, 2022, pp. PDF 29 y 33-34. Metodología oficial. MINEDU/ESCALE: ficha SIAGIE de atraso, edad al 31 de marzo y desfase de al menos dos años.

[5] INEI. ENAHO 2024: Manual de Consistencia Básica. Definición de residente habitual.

Material complementario: código de análisis, notebooks ejecutados, diccionario de variables y tablas de validación, ponderación, estabilidad y explicabilidad. La procedencia de las fuentes y sus verificaciones de integridad se documentan en el repositorio.